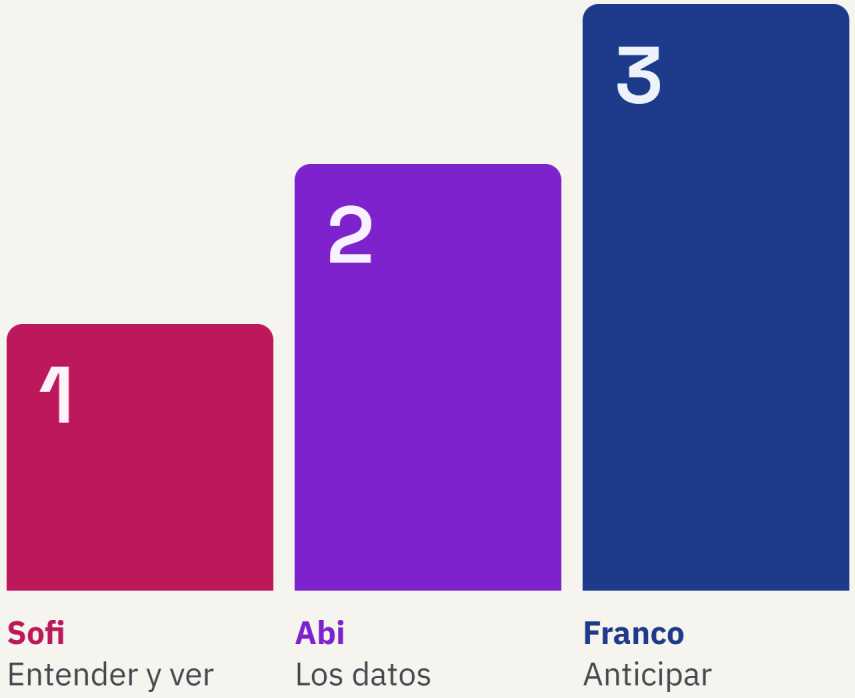
Industria 4.0 · Ingeniería Industrial, FIUNA · Grupo 2

Big Data e IA aplicada

Qué datos necesita una pyme para pasar de ver lo que pasó a anticipar lo que viene



Caso: **Casa Rojas (Fideos Napoli)**, referente del rubro alimenticio

Sofía Ferreiro · Abigail Ruiz Díaz · Franco Cazal · Semana 1, sesión A

Sofi · Apertura · La pregunta que nos tocó responder

¿Qué nivel de madurez de datos (calidad, frecuencia, historización) requiere una pyme para pasar de reportes descriptivos (BI) a modelos predictivos (ML), y qué herramientas open-source permiten hacerlo sin licencias costosas?

En palabras simples

¿Qué datos tiene que tener una empresa, y de qué calidad, para que valga la pena usar IA en lugar de solo mirar reportes? ¿Y se puede hacer sin pagar licencias caras?

> Antes de predecir, una empresa tiene que poder ver lo que pasa; y antes de ver, tiene que registrar bien sus datos.

Sofi · Apertura

Un solo recorrido en tres escalones

1 · Entender y ver

¿Qué pasa en la empresa y cómo lo vemos?

Sofi · 10 min

2 · De dónde salen los datos

¿Con qué datos y herramientas se construye lo que vimos?

Abi · 7 min

3 · Anticipar

¿Cuándo conviene predecir, y con qué confianza?

Franco · 11 min, y al final la demo en vivo de 7 min

En cada escalón, dos miradas con el mismo peso

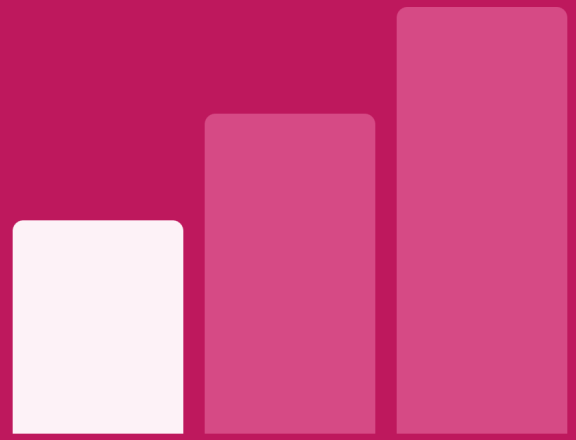
Comercial: ventas, stock, clientes

Operativa: máquinas, producción, mantenimiento

Escalón 1 de 3

Entender y ver

¿Qué pasa en la empresa y cómo lo vemos?



Sofi · 10 minutos

Sofi · Escalón 1 · Entender y ver

Analizar datos es responder cuatro preguntas

Mirada	¿Qué pasó? Descriptivo	¿Por qué pasó? Diagnóstico	¿Qué va a pasar? Predictivo	¿Qué conviene hacer? Prescriptivo
Comercial	Cuánto se vendió	Si las ventas cayeron por un quiebre de stock	Cuánto se va a vender el mes que viene	Cuánto stock enviar a cada depósito
Operativa	Cuántas horas estuvo parada una máquina	Si paró por falta de mantenimiento	Qué máquina está por fallar	Cuándo programar el mantenimiento
Quién la responde	**BI: reportes y dashboards responden estas dos**		**ML: el salto que estudiamos**	**Decide una persona, con datos**

Escalera analítica: Lepenioti et al. (2020)

Sofi · Escalón 1 · Entender y ver

Big Data se define con cinco V

Las tres originales (Laney, 2001)

Volumen

Mucha cantidad

Millones de ventas diarias de un supermercado

Velocidad

Llegan y se procesan rápido

Sensores que miden cada segundo

Variedad

Distintos formatos

Facturas, fotos y mensajes de WhatsApp

Las que se sumaron después

Veracidad

Cuánto se puede confiar

Stock cargado a mano, con errores

Valor

Si sirven para decidir

Saber qué reponer antes de que falte

Una pyme rara vez tiene el volumen de Big Data: su problema es la veracidad, o sea la calidad.

Hasta el dataset de nuestra demo, con un millón de filas, entra en una computadora común. Por eso hablamos de madurez y calidad, más que de tamaño.

Laney (2001); Lee, Kao y Yang (2014)

Sofi · Escalón 1 · Contexto local

Las pymes paraguayas en números

98%

de las empresas son mipymes

73%

del empleo está en ellas

96%

de las más de 300.000 registradas son microempresas

Lo que les falta, en 458 mipymes medidas con el Chequeo Digital del BID

Infraestructura

10%

no tiene internet

Capital humano

50%

no capacita en herramientas digitales

Gestión

85%

no tiene un plan digital

La oportunidad: la factura electrónica

21.000 → 44.923

emisores, de fines de 2025 a julio de 2026. Cada factura es un dato ordenado de qué se vendió, a quién y cuándo.

PNUD (2025a), con datos del INE; PNUD (2025b), proyecto Local Digital; Última Hora (2026)

Sofi · Escalón 1 · El caso

Nuestro caso: Casa Rojas (Fideos Napoli)

1924 nace como almacén con panadería sobre Pettirossi

1.400 t de fideos por mes, aproximadamente, en San Lorenzo

245 empleos directos

2 depósitos, en Encarnación y Ciudad del Este

También vende harinas, galletitas Capri, yerba Don Hilarión y balanceado Aliforte.

Dos decisiones que dependen de datos

Comercial · la que mostramos en la demo

Cuánto stock tener en cada depósito para no perder ventas sin inmovilizar plata

Operativa

Cuándo parar una línea para hacerle mantenimiento antes de que falle

Es grande, no pyme. La usamos como referente del rubro; la pregunta se responde para una pyme del mismo rubro.

Los datos de la demo no son suyos. Usamos un dataset público con la misma estructura: un simulador de vuelo.

Díaz (2020), InfoNegocios; dataset de la demo: Zhao (2017), Kaggle

Sofi · Escalón 1 · Métricas de la empresa

KPIs: un número que dice si vamos bien

Comercial

KPI	Cómo se calcula
Ventas	Unidades o guaraníes, por producto, depósito y mes
Margen bruto	(Ventas – costo de lo vendido) / ventas
Días de cobertura	Stock actual / venta diaria promedio
Quiebres de stock	Días o productos sin stock / total
Precisión del pronóstico	Lo pronosticado contra lo vendido

Operativa

KPI	Cómo se calcula
OEE	Disponibilidad × rendimiento × calidad
Disponibilidad	Tiempo produciendo / tiempo planificado
Paradas no planificadas	Horas o cantidad de paradas por mes
Tasa de defectos	Unidades defectuosas / unidades producidas
MTBF (tiempo medio entre fallas)	Tiempo funcionando / cantidad de fallas

Ejemplo de OEE disponibilidad 0,90 × rendimiento 0,95 × calidad 0,98 = **83,8%**

OEE: Nakajima (1988). Filas en azul: KPI puente hacia el escalón 3.

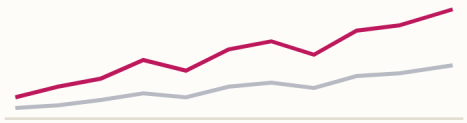
Sofi · Escalón 1 · Visualización

Un gráfico por pregunta, un tablero por mirada

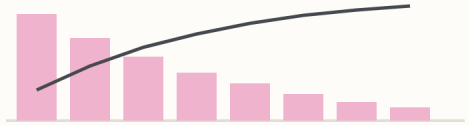
Tablero comercial

Demanda del mes | Días de cobertura | Quiebres de stock

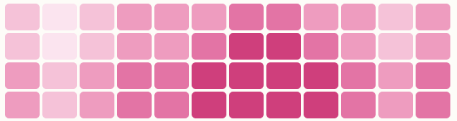
¿Cómo evolucionó la demanda? · línea



¿Qué categorías venden más? · Pareto



¿Hay estacionalidad? · mapa de calor



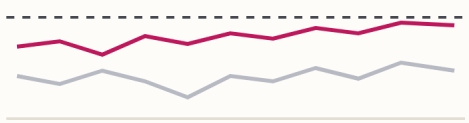
¿Cuánto se equivoca el pronóstico? · real contra pronóstico



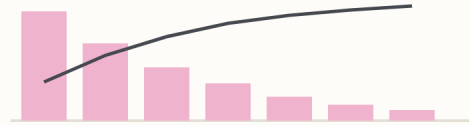
Tablero operativo

OEE semanal | Disponibilidad | Paradas no planificadas

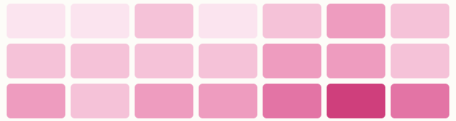
¿Cómo evolucionó el OEE? · línea con meta



¿Qué causa las paradas? · Pareto



¿Cuándo hay más defectos? · mapa de calor



¿Qué máquina está por fallar? · señal contra umbral



Bocetos sin datos reales. Paneles con borde azul: el puente hacia el escalón 3. Few (2006).

Sofi · Lo que el escalón 1 aporta a la respuesta

Para ver, hay que registrar cada hecho completo y con fecha

Comercial

Cada venta con fecha, producto, cantidad y lugar

Operativa

Cada parada con máquina, causa y duración

> **En nuestro dataset:** de 7 KPIs comerciales, solo se pueden calcular 2, ventas en unidades y precisión del pronóstico. Margen, rotación, cobertura y quiebres necesitan precio, costo y stock, que no se registraron.

La respuesta, en construcción

Sigue Abi: ¿de dónde salen esos datos? →

1 · Para ver: registrar

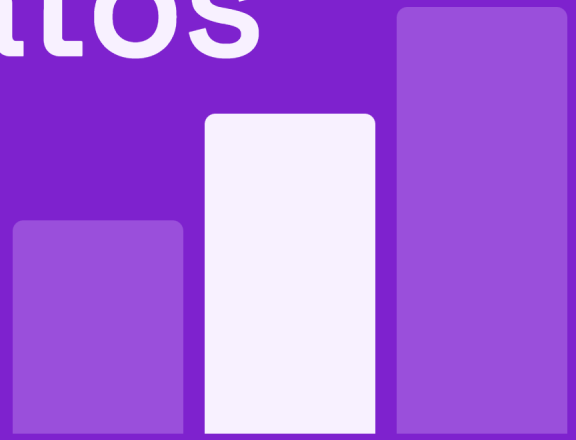
2 · Para confiar: calidad

3 · Para anticipar: madurez

Escalón 2 de 3

De dónde salen los datos

¿Con qué datos y herramientas se construye lo que vimos?



Abi · 7 minutos

Los datos nacen en lugares distintos

Fuente	Mirada	Qué registra	Qué tan ordenada está
Factura electrónica	Comercial	Qué se vendió, a quién, cuándo y a qué precio	Muy ordenada: formato fijo de la DNIT
ERP y punto de venta	Comercial	Ventas, stock, compras y clientes	Ordenado, si se carga bien
Pedidos por WhatsApp	Comercial	Conversaciones con clientes	Desordenados: texto libre
Registros de producción y mantenimiento	Operativa	Unidades producidas, paradas, causas y reparaciones	Muchas veces en papel o en planillas sueltas
Sensores de máquinas	Operativa	Temperatura, vibración, consumo de energía	Ordenados, pero en gran volumen
Planillas de Excel	Las dos	Lo que cada persona decidió anotar	Variable: cada uno usa su formato

> **Estructurados:** filas y columnas. **No estructurados:** texto libre, fotos, audios. Para analizarlos, casi todo tiene que terminar en filas y columnas.

Abi · Escalón 2 · El proceso

El pipeline funciona como una cocina

ETL: extraer, transformar y cargar

Extraer

Comprar los ingredientes

Sacar los datos de facturas, ERP o planillas

→

Transformar

Lavar y cortar

Limpiar, corregir y unificar formatos

→

Cargar

Guardar ordenado en la heladera

Dejarlos en una base o un archivo limpio

→

Analizar o modelar

Cocinar

Calcular KPIs o entrenar un modelo

→

Servir

Llevar el plato a la mesa

Dashboard, informe o pronóstico

La metodología más usada, CRISP-DM: seis fases que se repiten

1 · Entender el negocio

2 · Entender los datos

3 · Preparar: la que más trabajo lleva

4 · Modelar

5 · Evaluar

6 · Desplegar

Antes de modelar se hace un **EDA**, análisis exploratorio: mirar los datos con gráficos y resúmenes para encontrar errores y patrones.

CRISP-DM: Wirth y Hipp (2000)

Abi · Escalón 2 · Calidad de datos, ISO/IEC 25012

Basura entra, basura sale

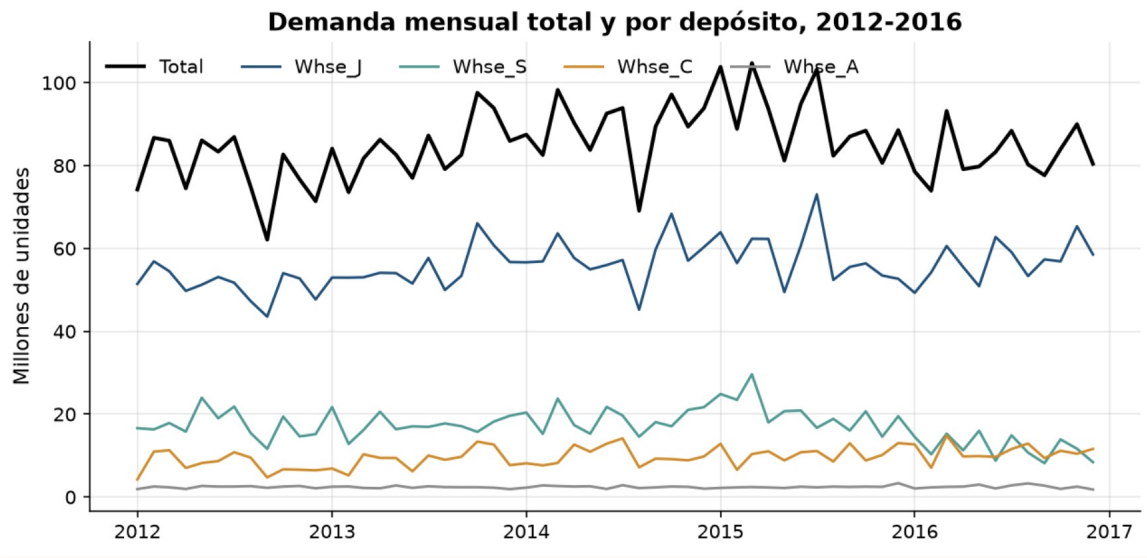
Característica	Qué pide	Lo que encontramos en nuestro dataset	Lo mismo en una planta
Completitud	Que no falten datos	11.239 filas sin fecha, todas de un mismo depósito	Paradas que nadie anotó
Exactitud	Que el dato sea correcto	10.469 demandas negativas y 28.681 pedidos en cero	Un sensor descalibrado
Consistencia	Que se registre siempre igual	Demanda guardada como texto, con paréntesis y espacios	La misma falla con tres nombres
Actualidad	Que esté al día y completo	2011 y 2017 incompletos: quedan afuera	Paradas cargadas a fin de mes
Credibilidad	Que se pueda confiar en el origen	Justo el tope de filas de Excel; 2016 trae 11% menos filas	Tiempos estimados de memoria
Trazabilidad	Que se sepa de dónde viene	122.423 filas idénticas, sin número de pedido	Reparación sin registro de quién la hizo

ISO/IEC 25012:2008, modelo de calidad de datos. Hallazgos calculados en el notebook 01.

Abi · Escalón 2 · Limpieza y primer análisis

De un archivo crudo a un panel limpio

Historical Product Demand: pedidos de un fabricante con 4 depósitos, 33 categorías y 2.160 productos, de 2011 a 2017.



Cómo la limpiamos

1. Texto a número; paréntesis a negativos
2. Sin fecha, afuera: 0,11% del volumen
3. Solo años completos, 2012 a 2016
4. Devoluciones aparte: 0,29% de la demanda
5. Panel mensual de 2.849 series producto × depósito

Lo que ya se ve: entre 60 y 105 millones de unidades por mes, y un depósito con casi dos tercios del volumen.

Zhao (2017), Kaggle. Bitácora de limpieza y gráfico del notebook 01.

Herramientas para ver y para predecir

Para ver: BI y visualización

Herramienta	Costo	Límite
Excel o Google Sheets	Sheets gratis; Excel con Microsoft 365	Se traba con muchos datos
Power BI	Gratis para crear; USD 14 por usuario al mes para compartir	Solo Windows
Looker Studio	Gratis	Depende de Google
Tableau	Pago, por usuario	Caro para una pyme
Metabase	Open source (AGPL)	Servidor propio
Apache Superset	Open source (Apache 2.0)	Servidor propio

Para preparar y predecir

Herramienta	Costo
Python y pandas	Gratis, open source
scikit-learn, LightGBM, statsforecast	Gratis, open source
Google Colab	Gratis con límites; necesita internet
Jupyter	Gratis; funciona sin internet

> Todo el camino hasta la predicción se hace sin licencias. **El costo real no es el software: es el tiempo de alguien que sepa usarlo.**

Precio de Power BI Pro desde abril de 2025: The Register (2025). Licencias: statsforecast Apache 2.0, LightGBM MIT.

Abi · Lo que el escalón 2 aporta a la respuesta

Para confiar, la revisión de calidad se repite siempre igual

Comercial

Un nombre por producto, ventas con fecha y devoluciones aparte

Operativa

Paradas anotadas al momento y cada falla con un solo nombre

Y sin licencias: **Python, Colab o Jupyter** para preparar y predecir; **Looker Studio o Metabase** para ver.

La respuesta, en construcción

Sigue Franco: ¿cuándo conviene predecir? →

1 · Para ver: registrar

2 · Para confiar: calidad

3 · Para anticipar: madurez

Escalón 3 de 3

Anticipar

¿Cuándo conviene predecir, y con qué confianza?



Franco · 11 minutos y la demo en vivo

No toda empresa necesita machine learning

Escala	Qué puede responder: comercial	Qué puede responder: operativa
Micro, hasta 10	¿Qué vendí hoy? ¿Qué está por agotarse?	¿Cuántas horas estuvo parada la máquina?
Pequeña, 11 a 30	¿Qué productos rotan? ¿Dónde pierdo margen?	¿Qué línea tiene el OEE más bajo?
Mediana, 31 a 50	¿Hay estacionalidad? ¿Cuánto voy a vender, aproximadamente?	¿Qué causa la mayoría de las paradas?
Grande e industrial	¿Cuánto stock tener en cada depósito?	¿Qué máquina va a fallar la semana que viene?

> **El matiz:** lo que decide no es la cantidad de trabajadores, sino cuántos productos y transacciones hay y cuánto cuesta equivocarse. Con 20 productos alcanza el ojo del encargado; con 2.000, no.

El primer escalón es registrar. En ventas, un sistema de gestión o una planilla bien llevada; un ejemplo local para micro y pequeñas es Focal Point. En la planta, un registro de paradas con campos fijos. **Declaración de interés:** Franco es co-fundador de Focal Point.

Escala por cantidad de trabajadores según la Ley N° 7444 (2025). Cada fila necesita la anterior: no se anticipa lo que nunca se registró.

Dos preguntas, dos niveles de datos

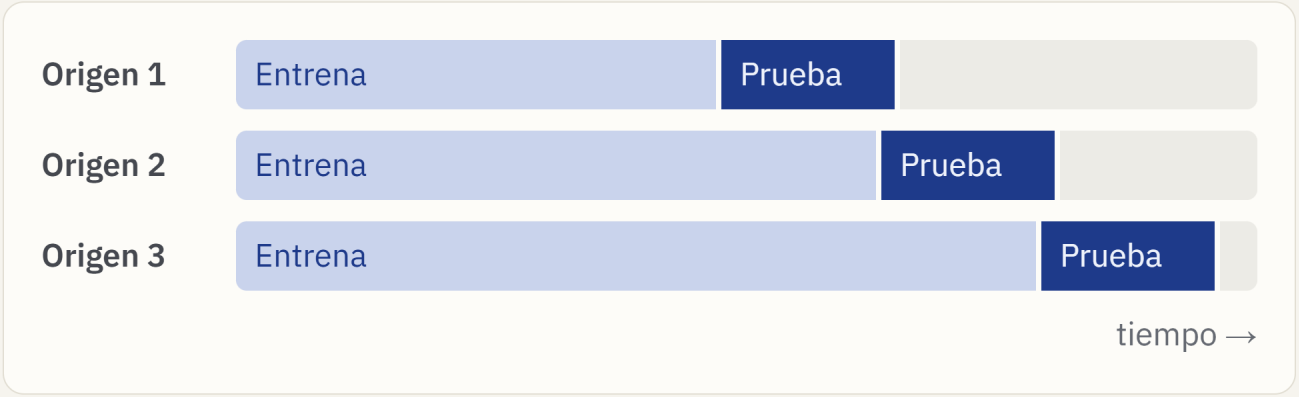
Machine learning: programas que aprenden patrones a partir de ejemplos con la respuesta conocida.

Requisito	Demanda: ¿cuánto? Regresión	Fallas: ¿sí o no? Clasificación
Dato base	Historia de ventas por producto y fecha	Lecturas de sensores y registro de cada falla
Quién lo tiene hoy	Casi toda pyme, en sus facturas	Muy pocas pymes
Frecuencia	La de la decisión: mensual para producir	Minutos o segundos
Dificultad principal	Separar tendencia, estacionalidad y ruido	Las fallas son raras: hay pocos ejemplos
Costo de arrancar	Bajo: los datos ya existen	Alto: sensores, instalación y conectividad

> Por eso medimos demanda: es el dato que una pyme ya tiene. Las fallas las profundizan los grupos 1 (sensores) y 5 (mantenimiento predictivo).

Un modelo se prueba como un examen

Validación temporal: se entrena con el pasado, se prueba con lo que vino después, y se repite desde varios orígenes.



Con datos hasta el cierre de un mes se pronostica el mes subsiguiente, como la empresa del dataset: sus productos tardan más de un mes en llegar.

Sin fugas del futuro

Nada posterior a la fecha de corte entra al entrenamiento.

Ojo con el sobreajuste

Memorizar el examen del año pasado: perfecto con lo viejo, mal con lo nuevo.

Siempre contra un baseline

Si el modelo no le gana a un método simple, no vale la pena.

Se elige con 2015

y se prueba con 12 meses de 2016 que no se tocaron al elegir.

Validación con varios orígenes: Tashman (2000); Bergmeir y Benítez (2012)

Siete modelos, de lo más simple al ML

Modelo	Cómo pronostica	Familia
Naive	"Se va a vender lo mismo que el último mes"	Referencia
Naive estacional	"Lo mismo que el mismo mes del año pasado"	Referencia
Media móvil	El promedio de los últimos 12 meses; la ventana se eligió con 2015	Referencia, la regla de la pyme
Croston SBA	Para venta intermitente: estima cuánto y cada cuánto, por separado	Clásico
ETS	Suavizado exponencial por serie, con estacionalidad si hay dos años	Estadístico
Ridge	Regresión lineal con las mismas variables, una para todas las series	ML lineal
LightGBM	Muchos árboles chicos; cada uno corrige los errores del anterior	ML con árboles

Competencia M5, ventas minoristas

Los métodos ganadores usaron LightGBM

Competencia M3, series mensuales

Los métodos estadísticos le ganaron al ML

Entonces

El ML no gana siempre: eso es lo que medimos

Croston (1972); Syntetos y Boylan (2005); Ke et al. (2017); Makridakis et al. (2018, M3; 2022, M5)

Franco · Escalón 3 · Métricas

Cómo medimos cuánto nos equivocamos

Pronóstico: cuánto

Ejemplo inventado: demanda real de 200, 260 y 140; pronóstico de 220 cada mes. Error total: 140 sobre 600.

MAE 140 / 3 = 46,7 unidades
el error promedio de cada mes

WAPE 140 / 600 = 23,3%
el error sobre el volumen total

Sesgo (660 – 600) / 600 = +10%
el pronóstico se pasó

MASE error / error del naive
pesa igual series grandes y chicas

Sin MAPE: divide por la demanda de cada mes, y un mes en cero no se puede calcular.

Clasificación: sí o no

Ejemplo inventado: en 1.000 días hubo 30 fallas. El modelo dio 40 alarmas y 24 fueron fallas reales.

Precisión 24 / 40 = 60%
de las alarmas, cuántas eran fallas

Recall 24 / 30 = 80%
de las fallas, cuántas anticipó

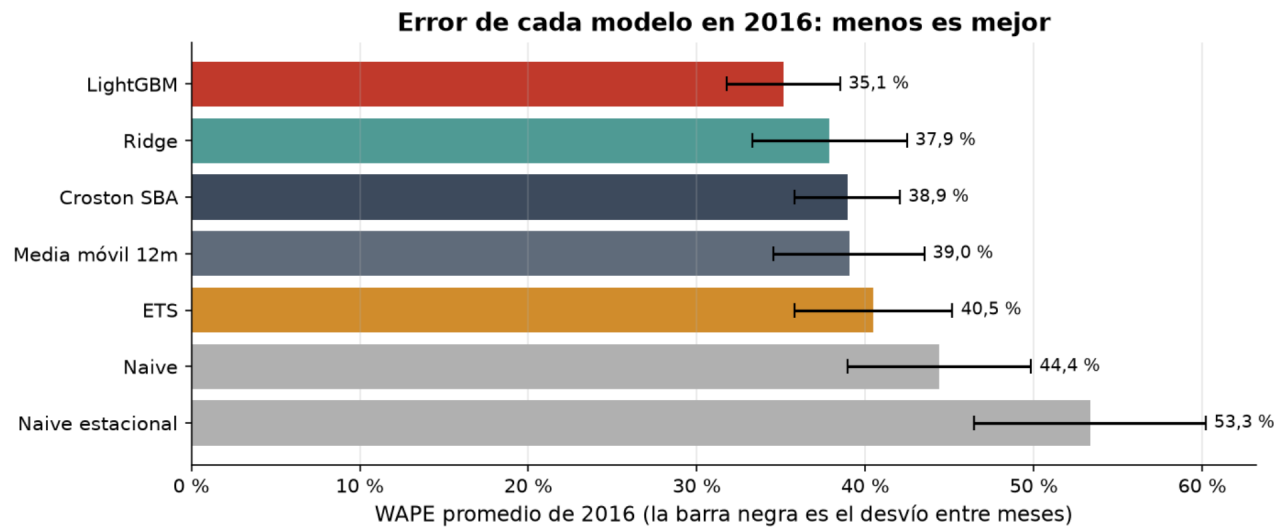
F1 69%
un promedio entre las dos

La trampa del accuracy, en nuestros datos: decir siempre "habrá pedido" acierta el 79,3% de los meses y no detecta ningún mes sin pedido. La logística balanceada acierta menos, 77,6%, pero detecta 2 de cada 3.

MASE: Hyndman y Koehler (2006). Datos desbalanceados: He y Garcia (2009). Trampa medida en el anexo del notebook 02.

Franco · Escalón 3 · Resultados con todos los datos

Con todos los datos, el ML gana



10%

menos error de LightGBM que la media móvil de 12 meses: WAPE de 35,1% contra 39,0%

- Probado en los 12 meses de 2016, a dos meses vista
- Sesgo de −8,8%: pide de menos, porque estima la mediana

Dónde gana

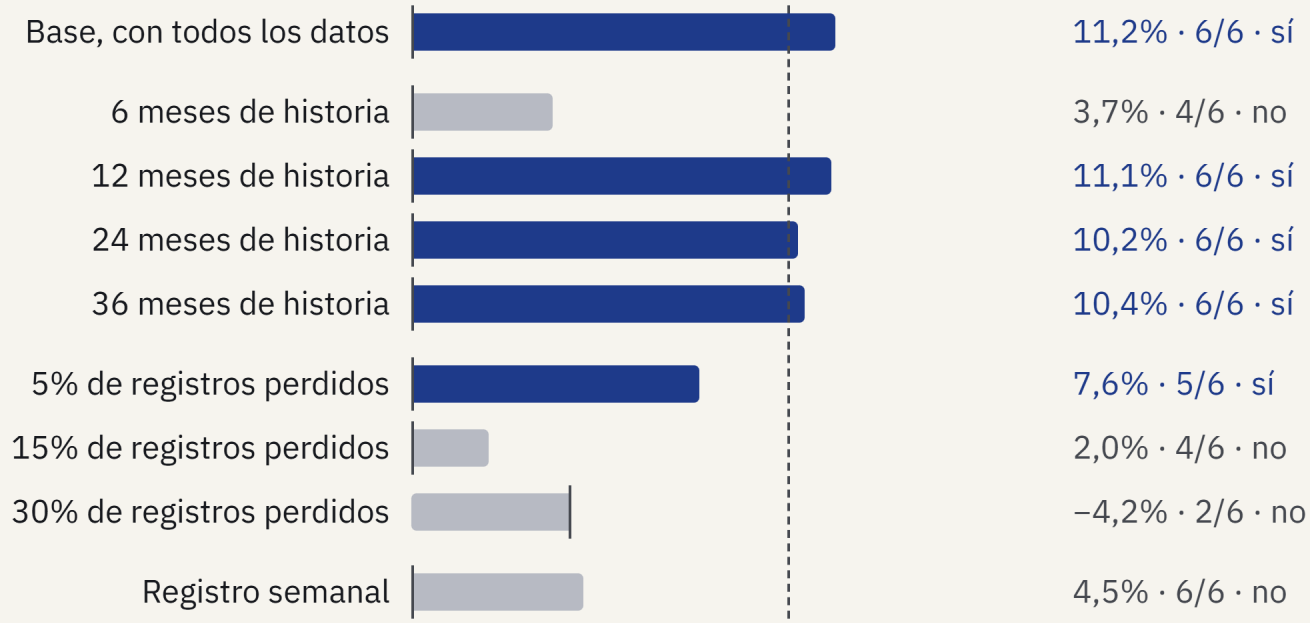
En series erráticas, 17% menos error. En el depósito J, con el 69% del volumen, solo 3,4%.

> La pregunta de fondo: ¿sigue ganando con los datos de una pyme? Eso mide el experimento.

Notebook 02: prueba con origen móvil de enero a diciembre de 2016; selección hecha antes, con 2015.

Franco · Escalón 3 · El experimento de madurez

Desde dónde vale la pena el ML



Mejora sobre la mejor referencia simple · meses ganados de 6 · umbral 5%

Criterio, declarado antes de correr

El mejor ML baja el WAPE al menos 5% contra la mejor referencia simple y gana en 4 de los 6 meses.

- **Historia:** con 12 meses ya gana 11%; con 6, no alcanza.
- **Calidad:** con 5% de registros perdidos todavía gana; con 15%, ya no.
- **Frecuencia:** registrar por semana no mejora el pronóstico del mes.

> Perder registros además sesga: el pronóstico baja tanto como lo que se dejó de registrar. Con 30% perdido, LightGBM subestima la demanda un 38%.

Notebook 03: nueve escenarios, un factor por vez, 6 meses de prueba de 2016 cada uno. El 5% es un supuesto de consultoría.

Franco · Cierre

La respuesta, completa

1 · Para ver
registrar

Cada venta con fecha, producto, cantidad y lugar; cada parada con máquina, causa y duración.

2 · Para confiar
calidad

Un control de calidad que se repite siempre igual. Todo sin licencias: Python, Colab o Jupyter, Looker Studio o Metabase.

3 · Para anticipar
madurez

Demanda: al menos 12 meses de historia continua y casi todas las ventas registradas (con 5% perdido todavía vale; con 15%, ya no), con la frecuencia de la decisión: mensual.

Fallas: primero medir la planta, con sensores y un registro de cada falla. Sin eso, el nivel alcanzable es el mantenimiento preventivo.

Franco · Escalón 3 · Propuesta viable

Propuesta para una pyme del rubro

1 · Registrar y ver

Factura electrónica o sistema de gestión, y una planilla de paradas con campos fijos

Looker Studio o Power BI Desktop

2 · Asegurar la calidad

Un control que se repite igual cada mes, documentado para que lo corra cualquiera

Python y pandas, en Colab o Jupyter

3 · Anticipar

Media móvil desde el día uno; LightGBM con 12 meses de historia y casi sin registros perdidos

statsforecast y LightGBM

Costo

Licencias: Gs 0 en los tres pasos (USD 14 por usuario al mes solo para compartir en Power BI). Lo que sí cuesta: [__] horas de capacitación y [__] horas al mes de una persona responsable.

Beneficio estimado

Quiebres evitados × margen perdido por quiebre + sobrestock evitado × costo de mantener stock = [Gs __ al mes]. Partimos del 10% menos de error medido; los guaraníes salen del precio y el costo de la pyme.

Con las restricciones reales: Sin internet: Jupyter local · Sin capacitación: se presupuesta · Sin plan digital: se empieza por el paso 1

Restricciones: PNUD (2025b). Precio de Power BI: The Register (2025). Los corchetes se completan con datos de la pyme: el dataset no tiene precios ni costos.

Franco · Cierre · Pensamiento crítico

Límites, riesgos y cómo validarlo

Qué medimos y qué suponemos

Afirmación	Qué es	Cómo se valida
Con todos los datos, el ML gana 10%	Medido, en un dataset público	Repetirlo con datos de la pyme
El umbral: 12 meses y no más de 5% perdido	Medido, pero no en Casa Rojas	Piloto en paralelo, varios meses
Lo que no se registra hace pedir de menos	Medido aquí y en Blindside	Registrar quiebres y comparar
Un tablero mejora las decisiones	Supuesto	Comparar antes y después
Sin sensores no se predicen fallas	Inferencia	Con el registro de una planta real

Riesgos y cómo los reducimos

Confianza falsa
un tablero lindo con datos malos convence igual: control de calidad

Datos sensibles
anonimizar y controlar quién accede

Una sola persona sabe
notebook documentado que otro pueda correr

El mercado cambia
medir el error cada mes y reentrenar

Franco · Demo en vivo · 7 minutos

Todo lo que vimos, funcionando

1 · Notebook 01
Limpieza y calidad: de texto crudo a panel mensual

1 minuto

2 · Notebook 02
Los siete modelos y el pronóstico de una serie, con su rango

2 minutos

3 · Notebook 03
El experimento de madurez, releído de la caché

2 minutos

4 · Blindside
El quiebre de stock que casi nadie registra

2 minutos

Si algo falla

- Sin internet: Jupyter local, con los notebooks ya ejecutados
- El experimento tarda 45 minutos: la caché lo relee en segundos
- Si nada corre: la slide siguiente y las figuras del informe

Grupo 2 · Cada uno responde las preguntas de su parte

Gracias. ¿Preguntas?

Sofi

- Análisis de datos y Big Data
- Pymes paraguayas y el caso
- KPIs y tableros en Power BI

Abi

- Fuentes y pipeline
- Calidad de datos
- Herramientas y costos

Franco

- Cuándo pasar a ML
- Modelos y experimento
- Propuesta, demo y Blindside

Material: informe técnico, notebook en Colab, tablero en Power BI y ficha de caso con datos del contexto paraguayo.

Referencias

Bergmeir, C., y Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213.

Cazal, F. (2026). *Blindside* [Proyecto final, Diplomado en Machine Learning y Deep Learning Aplicado]. FIUNA.

Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly, 23*(3), 289–303.

Díaz, D. (2020). Hecho en Py: Fideos Napoli espera un 2021 favorable para la exportación. *InfoNegocios*.

Few, S. (2006). *Information dashboard design*. O'Reilly Media.

He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284.

Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688.

ISO/IEC. (2008). *ISO/IEC 25012:2008. Software engineering: Data quality model*. ISO.

Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*.

Laney, D. (2001). *3D data management: Controlling data volume, velocity and variety*. META Group.

Lee, J., Kao, H.-A., y Yang, S. (2014). Service innovation and smart analytics for Industry 4.0 and big data environment. *Procedia CIRP, 16*, 3–8.

Lepenioti, K., Bousdekis, A., Apostolou, D., y Mentzas, G. (2020). Prescriptive analytics: Literature review and research challenges. *International Journal of Information Management, 50*, 57–70.

Referencias

Ley N° 7444. (2025). *Que modifica y amplía la Ley N° 4457/2012 de las micro, pequeñas y medianas empresas*. República del Paraguay.

Makridakis, S., Spiliotis, E., y Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE, 13*(3), e0194889.

Makridakis, S., Spiliotis, E., y Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting, 38*(4), 1346–1364.

Nahmias, S. (1994). Demand estimation in lost sales inventory systems. *Naval Research Logistics, 41*(6), 739–757.

Nakajima, S. (1988). *Introduction to TPM: Total productive maintenance*. Productivity Press.

PNUD. (2025a). *¿Qué tan preparadas están las MIPYMES en Paraguay para la transformación digital?*

PNUD. (2025b). *Digitalización y MIPYMES en Paraguay: madurez digital y espíritu emprendedor*.

Syntetos, A. A., y Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting, 21*(2), 303–314.

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting, 16*(4), 437–450.

The Register. (2025). Precios de Power BI desde abril de 2025.

Última Hora. (2026). DNIT incorporó a 5.961 emisores electrónicos en menos de dos meses.

Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.

Zhao, F. (2017). *Forecasts for product demand* [Conjunto de datos]. Kaggle.

Formato APA 7. La lista completa está en el informe técnico.