Guía de estudio

Grupo 2 · Big Data e IA aplicada · Caso: Casa Rojas (Fideos Napoli)

Versión
Primer borrador · 13/10/2026

Para qué sirve
Estudiar el tema antes de las slides

Colores por integrante
Sofi Abi Franco

Cómo usar esta guía

La exposición es un solo recorrido en tres escalones. Lean la guía completa una vez y después estudien su escalón en detalle. **Cada color marca de quién es cada parte**, en esta guía y en el plan del grupo.

Escalón	Quién	Pregunta que responde	Minutos
1 · Entender y ver	Sofi	¿Qué pasa en la empresa y cómo lo vemos?	12
2 · De dónde salen los datos	Abi	¿Con qué datos y herramientas se construye lo que vimos?	9
3 · Anticipar	Franco	¿Cuándo conviene predecir, y con qué confianza?	15

La pregunta que tenemos que responder, tal como la escribió el profesor:

> ¿Qué nivel de madurez de datos (calidad, frecuencia, historización) requiere una pyme para pasar de reportes descriptivos (BI) a modelos predictivos (ML), y qué herramientas open-source permiten hacerlo sin licencias costosas?

En palabras simples: ¿qué datos tiene que tener una empresa, y de qué calidad, para que valga la pena usar inteligencia artificial en lugar de solo mirar reportes? ¿Y se puede hacer sin pagar licencias caras?

La idea que une todo: antes de predecir, una empresa tiene que poder ver lo que pasa; y antes de ver, tiene que registrar bien sus datos.

Las dos miradas: cada escalón mira dos lados de la empresa, el comercial (ventas, stock y clientes) y el operativo (máquinas, producción y mantenimiento). Las dos pesan igual en los conceptos. La demo usa la mirada comercial, porque son los datos que una pyme ya tiene; la operativa aparece como contraste, para mostrar qué datos le faltan a una pyme para llegar ahí.

Cada escalón termina con dos ayudas: **Dicho con tus palabras**, para exponer sin leer, y **Te pueden preguntar**, con las contra-preguntas probables. Los términos nuevos están en el glosario del final.

Escalón 1 · Entender y ver

Sofi · 12 min

1.1 Qué es un dato y qué es analizar datos

Un dato es el registro de un hecho: "el 3 de marzo se vendieron 40 paquetes de fideos en Encarnación", o "el martes la línea 2 estuvo parada 40 minutos por un atasco". Solo dice poco; junto con miles de registros parecidos, muestra patrones.

Analizar datos es ordenarlos, resumirlos y compararlos para decidir mejor. El análisis responde cuatro preguntas, de menor a mayor dificultad:

1. **¿Qué pasó?** Descriptivo: cuánto se vendió, o cuántas horas estuvo parada una máquina.
2. **¿Por qué pasó?** Diagnóstico: si las ventas cayeron por un quiebre de stock, o si la máquina paró por falta de mantenimiento.
3. **¿Qué va a pasar?** Predictivo: cuánto se va a vender el próximo mes, o qué máquina está por fallar.
4. **¿Qué conviene hacer?** Prescriptivo: cuánto stock enviar a cada depósito, o cuándo programar el mantenimiento.

Los reportes y dashboards (BI) responden las dos primeras. El machine learning (ML) entra en la tercera. Nuestra pregunta de investigación es justamente qué necesita una empresa para dar ese salto.

1.2 Qué es Big Data, y por qué una pyme casi nunca lo tiene

Big Data son datos tan grandes, rápidos o variados que las herramientas tradicionales no alcanzan. Laney (2001) lo definió con tres V, y después se sumaron dos más:

V	Qué significa	Ejemplo
Volumen	Mucha cantidad	Millones de ventas diarias de una cadena de supermercados
Velocidad	Llegan rápido y hay que procesarlos rápido	Sensores de una máquina que miden cada segundo
Variedad	Distintos formatos	Facturas, fotos, mensajes de WhatsApp
Veracidad	Cuánto se puede confiar en ellos	Stock cargado a mano con errores
Valor	Si sirven para decidir algo	Saber qué producto reponer antes de que falte

En la Industria 4.0, el análisis de datos convierte lo que pasa en la planta y en el mercado en decisiones (Lee, Kao y Yang, 2014).

> **La idea crítica que nos diferencia:** una pyme rara vez tiene el volumen de Big Data. Su problema casi siempre es la veracidad, o sea la calidad. Hasta el dataset de nuestra demo, con un millón de filas, entra en una computadora común. Por eso el trabajo se enfoca en madurez y calidad de datos más que en tamaño.

1.3 Las pymes paraguayas

- Son el 98% de las empresas y el 73% del empleo. Hay más de 300.000 registradas, y el 96% son microempresas (PNUD, 2025a, con datos del INE).
- La ley las clasifica por trabajadores y facturación anual (Ley N° 7444, 2025):

Categoría	Trabajadores	Facturación anual hasta
Microempresa	Hasta 10	Gs. 646 millones

Categoría	Trabajadores	Facturación anual hasta
Pequeña empresa	11 a 30	Gs. 3.230 millones
Mediana empresa	31 a 50	Gs. 7.750 millones, aproximadamente

- **Madurez digital.** El proyecto Local Digital midió 458 mipymes con el Chequeo Digital del BID, que las ubica en cuatro niveles (inicial, novato, competente y avanzado) e incluye una dimensión de uso de datos (PNUD, 2025b).
- **Barreras.** El 10% no tiene internet, el 50% no capacita a su personal en herramientas digitales y el 85% no tiene un plan digital (PNUD, 2025b).
- **Oportunidad.** La factura electrónica crece rápido: de unos 21.000 emisores a fines de 2025 a 44.923 en julio de 2026 (Última Hora, 2026). Cada factura electrónica es un dato ordenado de qué se vendió, a quién y cuándo.

1.4 Nuestro caso: Casa Rojas (Fideos Napoli)

Casa Rojas nació en 1924 como un almacén con panadería sobre Pettirossi. Hoy fabrica unas 1.400 toneladas de fideos por mes en San Lorenzo, tiene depósitos en Encarnación y Ciudad del Este y 245 empleos directos. Además de fideos, vende harinas, galletitas Capri, yerba Don Hilarión y balanceado Aliforte (Díaz, 2020).

La elegimos porque todos la conocen y porque tiene decisiones que dependen de datos en los dos lados:

- **Comercial:** cuánto stock tener en cada depósito para no perder ventas sin inmovilizar plata. Es la que mostramos en la demo.
- **Operativa:** cuándo conviene parar una línea de producción para hacerle mantenimiento antes de que falle.

Dos aclaraciones que hay que saber decir:

- **Es una empresa grande**, no una pyme. La usamos como referente del rubro, y la pregunta se responde para una pyme del mismo rubro.
- **Los datos de la demo no son de Casa Rojas.** Usamos un dataset público de una fábrica con la misma estructura (planta, depósitos y muchas categorías). Es como un simulador de vuelo: no es el avión real, pero tiene los mismos controles.

1.5 Métricas empresariales (KPIs)

Un KPI (indicador clave de desempeño) es un número que dice si la empresa va bien en algo que importa, comparado con una meta o con el pasado. La guía del TP menciona datos industriales como OEE, defectos y demanda.

KPIs comerciales

KPI	Cómo se calcula	Qué pregunta responde
Ventas por producto, depósito y mes	Suma de unidades o guaraníes vendidos	¿Dónde y cuándo se vende?
Margen bruto	(Ventas − costo de lo vendido) / ventas	¿Cuánto se gana por cada guaraní vendido?
Rotación de inventario	Costo de lo vendido / inventario promedio	¿Cuántas veces se renueva el stock en el período?
Días de cobertura	Stock actual / venta diaria promedio	¿Para cuántos días alcanza lo que hay?
Tasa de quiebre de stock	Días o productos sin stock / total	¿Cuántas veces no había para vender?

KPI	Cómo se calcula	Qué pregunta responde
Nivel de servicio	Unidades entregadas a tiempo / unidades pedidas	¿Qué parte de los pedidos se cumplió?
Precisión del pronóstico de ventas	Comparación entre lo pronosticado y lo vendido	¿Cuánto nos equivocamos al planificar?

KPIs operativos

KPI	Cómo se calcula	Qué pregunta responde
OEE	Disponibilidad × rendimiento × calidad (Nakajima, 1988)	¿Qué parte del tiempo la máquina produjo bien y a buen ritmo?
Disponibilidad	Tiempo produciendo / tiempo planificado	¿Cuánto tiempo estuvo realmente funcionando?
Paradas no planificadas	Horas o cantidad de paradas por mes	¿Cuánto se pierde por imprevistos?
MTBF (tiempo medio entre fallas)	Tiempo de funcionamiento / cantidad de fallas	¿Cada cuánto falla una máquina?
MTTR (tiempo medio de reparación)	Tiempo total de reparación / cantidad de reparaciones	¿Cuánto se tarda en repararla?
Tasa de defectos	Unidades defectuosas / unidades producidas	¿Cuánto sale mal?
Merma	Unidades perdidas o dañadas / unidades totales	¿Cuánto se desperdicia?

Ejemplo de OEE: si una línea estuvo disponible el 90% del tiempo, funcionó al 95% de su velocidad y el 98% de lo producido salió bien, su OEE es 0,90 × 0,95 × 0,98 = 83,8%.

Cada tabla tiene su KPI puente hacia el escalón 3: la precisión del pronóstico en lo comercial y el MTBF en lo operativo, porque anticipar ventas o fallas empieza por medir cuánto nos equivocamos y cada cuánto pasan las cosas. La demo usa los KPIs comerciales, que salen de las facturas. Los operativos necesitan medir la planta, y los grupos 1 (sensores) y 5 (mantenimiento) los profundizan.

1.6 Por qué visualizar, y cómo elegir el gráfico

Un gráfico se lee más rápido que una tabla. Un dashboard reúne en una sola pantalla la información más importante para un objetivo, para leerla de un vistazo (Few, 2006). Un buen gráfico responde una pregunta; uno malo obliga a buscar la respuesta.

Si la pregunta es...	Usá	Evitá
¿Cómo evolucionó en el tiempo?	Línea	Barras en 3D
¿Qué vende más?	Barras horizontales ordenadas	Torta con muchas porciones
¿Pocos productos explican la mayor parte?	Pareto: barras más una línea acumulada	Tabla larga sin orden
¿Qué causa la mayoría de las paradas?	Pareto de causas	Una lista de paradas sin agrupar

Si la pregunta es...	Usá	Evitá
¿Hay estacionalidad?	Mapa de calor de mes por año, o líneas por año superpuestas	Un solo total anual
¿Cómo está cada línea contra su meta?	Barras de OEE por línea, con la meta marcada	Un promedio de toda la planta
¿Cómo estamos contra la meta?	Tarjeta KPI con el valor y su comparación	Un número sin contexto
¿Se relacionan dos variables?	Dispersión	Dos ejes verticales que confunden

Errores comunes: barras con un eje que no arranca en cero, demasiados colores, gráficos en 3D, dashboards con veinte gráficos y datos sin el período al que corresponden.

1.7 Ejemplos: un tablero comercial y uno operativo

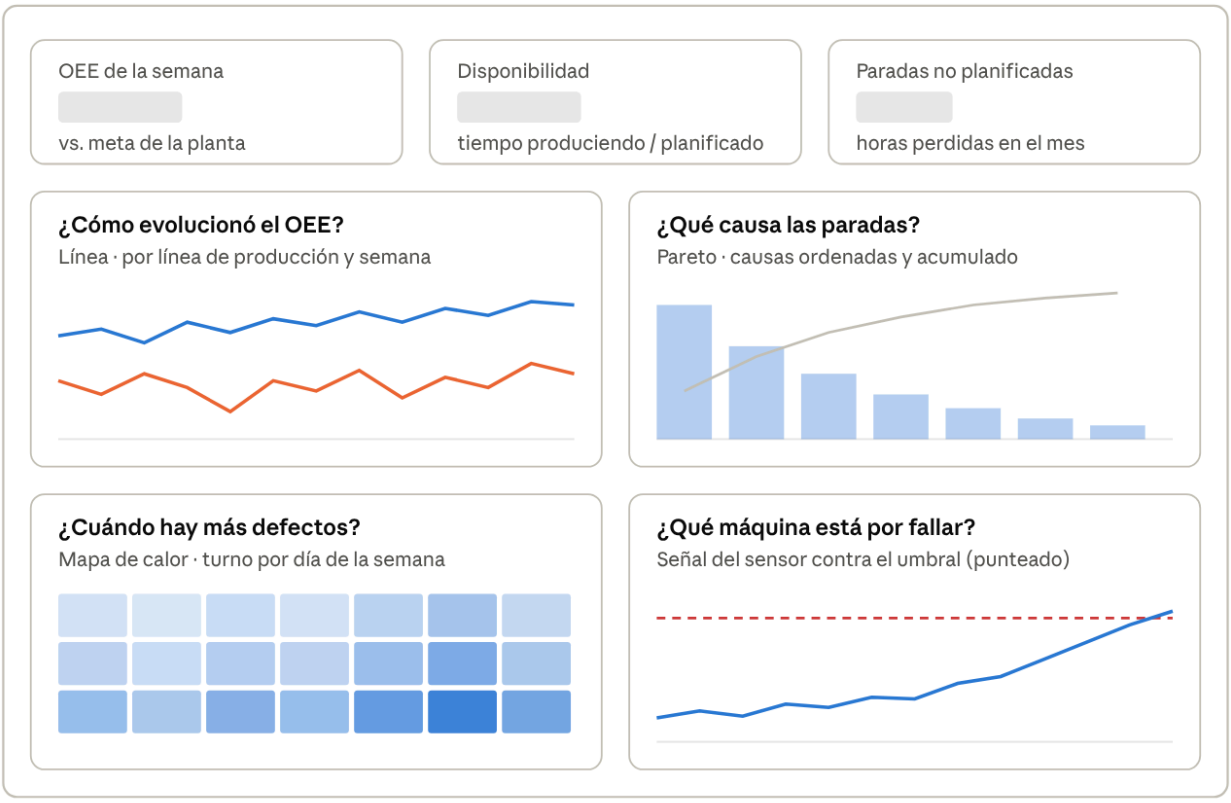
Un dashboard de demanda responde cuatro preguntas en una pantalla



Boceto sin datos reales: los gráficos con datos salen del dashboard en Power BI

Arriba, los KPIs que se miran primero; abajo, un gráfico por pregunta, cada uno del tipo que recomienda la tabla de 1.6. El último panel es el puente con el escalón 3.

Un tablero operativo responde cuatro preguntas sobre la planta



Boceto sin datos reales: muestra qué se ve cuando la planta registra sus paradas y sus sensores

El tablero operativo sigue la misma lógica: arriba los KPIs de la planta, abajo un gráfico por pregunta. El último panel muestra la idea del mantenimiento predictivo: una señal de la máquina que se acerca a un umbral.

Dicho con tus palabras (escalón 1)

- "Toda empresa genera datos cada vez que vende y cada vez que produce. Analizarlos es pasar de *creo que vendemos más en diciembre* o *creo que la máquina 2 para seguido* a saberlo con números."
- "Una pyme casi nunca tiene Big Data. Tiene datos chicos y desordenados: el desafío no es el tamaño, es la calidad."
- "Un dashboard es la foto del negocio o de la planta en una pantalla: cuánto se vende, cuánto se produce, y si vamos mejor o peor que antes."
- **Línea de cierre del bloque:** "Para tener BI, una empresa necesita registrar cada venta con fecha, producto, cantidad y lugar, y cada parada con máquina, causa y duración, sin huecos. Con eso ya puede ver qué pasó. Ahora veamos de dónde salen esos datos."

Te pueden preguntar (escalón 1)

Pregunta	Cómo responder
¿Los datos son de Casa Rojas?	No. Son de un dataset público de una fábrica con la misma estructura. Casa Rojas es el referente del rubro y sus datos no son públicos.
¿Por qué Casa Rojas, si la pregunta habla de pymes?	Porque muestra a dónde puede llegar una empresa del rubro. La pregunta se responde para la pyme: en el escalón 3 simulamos empresas más chicas recortando los datos.

Pregunta	Cómo responder
¿Por qué la demo es de ventas y no de máquinas?	Porque las ventas son el dato que una pyme ya tiene en sus facturas; los datos de máquinas necesitan sensores. Lo operativo lo mostramos como contraste, y los grupos 1 y 5 lo profundizan.
¿Por qué Power BI, si no es open source?	Lo pide la guía y es gratis para crear tableros. Para compartirlos hay que pagar una licencia, por eso lo comparamos con alternativas sin licencia en el escalón 2.
¿Qué KPI mirarías primero en una pyme?	En lo comercial, ventas por producto y quiebres de stock; en lo operativo, paradas no planificadas. Son fáciles de medir y mueven plata.
¿Qué afirmación necesita validación?	Que el dashboard mejora las decisiones. Se valida usándolo varios meses en una empresa real y comparando decisiones y resultados antes y después.
¿Qué riesgo no mencionaron?	Un dashboard con datos malos da una confianza falsa. Por eso el escalón 2 empieza por la calidad de los datos.

Escalón 2 · De dónde salen los datos

Abi · 9 min

2.1 Las fuentes de datos de una empresa

Fuente	Mirada	Qué registra	Qué tan ordenada está
Factura electrónica	Comercial	Qué se vendió, a quién, cuándo y a qué precio	Muy ordenada: formato fijo definido por la DNIT
Sistema de gestión (ERP) y punto de venta	Comercial	Ventas, stock, compras y clientes	Ordenado, si se carga bien
Pedidos por WhatsApp	Comercial	Conversaciones con clientes	Desordenados: texto libre
Registros de producción y mantenimiento	Operativa	Unidades producidas, paradas, causas y reparaciones	Muchas veces en papel o en planillas sueltas
Sensores de máquinas	Operativa	Temperatura, vibración, consumo de energía	Ordenados, pero en gran volumen
Planillas de Excel	Las dos	Lo que cada persona decidió anotar	Variable: cada uno usa su formato

Los datos **estructurados** vienen en filas y columnas; los **no estructurados** son texto libre, fotos o audios. Para analizarlos, casi todo tiene que terminar en filas y columnas.

2.2 El pipeline: la cocina de los datos

Un pipeline es la cadena de pasos que lleva un dato desde donde nace hasta un gráfico o un modelo. Funciona como una cocina: se compran los ingredientes (extraer), se lavan y se cortan (transformar), se guardan ordenados en la heladera (cargar), se cocinan (analizar o modelar) y se sirven (dashboard o informe). A los tres primeros pasos se los llama **ETL**: extraer, transformar y cargar.

La metodología más usada para proyectos de datos es **CRISP-DM**, con seis fases (Wirth y Hipp, 2000):

1. **Entender el negocio:** qué decisión queremos mejorar.
2. **Entender los datos:** qué hay, de dónde viene y qué le falta.
3. **Preparar los datos:** limpiar y ordenar. Suele ser la fase que más trabajo lleva.
4. **Modelar:** aplicar el análisis o el modelo.
5. **Evaluar:** ver si el resultado sirve para la decisión.
6. **Desplegar:** ponerlo a funcionar en la empresa.

Antes de modelar se hace un **EDA** (análisis exploratorio de datos): mirar los datos con gráficos y resúmenes para encontrar errores y patrones.

2.3 Calidad de datos: basura entra, basura sale

Si los datos de entrada son malos, el resultado también lo es, por más bueno que sea el modelo. La norma ISO/IEC 25012 (2008) define las características de calidad de un dato; estas son las que más le sirven a una pyme:

Característica	Qué significa	Ejemplo comercial	Ejemplo operativo
Completitud	Que no falten datos	Ventas sin fecha	Paradas que nadie anotó
Exactitud	Que el dato sea correcto	Se cargó 1.000 en vez de 100	Un sensor descalibrado

Característica	Qué significa	Ejemplo comercial	Ejemplo operativo
Consistencia	Que lo mismo se registre siempre igual	"Napoli 500 g" y "NAPOLI 500GR" como si fueran dos productos	La misma falla anotada con tres nombres distintos
Actualidad	Que el dato esté al día	El stock se actualiza una vez por semana	Las paradas se cargan a fin de mes
Credibilidad	Que se pueda confiar en su origen	Datos copiados de una planilla que nadie revisa	Tiempos de parada estimados de memoria
Trazabilidad	Que se sepa de dónde vino y quién lo cambió	Una planilla que pasó por cinco personas	Una reparación sin registro de quién la hizo

El dataset de nuestra demo trae problemas reales: más de 11.000 filas sin fecha, la demanda guardada como texto y valores negativos, que probablemente son devoluciones. Además tiene exactamente el máximo de filas de una hoja de Excel, así que pudo pasar por una planilla y quedar cortado. Estas cifras se confirman al correr el notebook.

2.4 Herramientas y contraste

Hay dos familias: herramientas para **ver** los datos (BI y visualización) y herramientas para **prepararlos y predecir** (programación).

Para ver: BI y visualización

Herramienta	Para qué sirve	Costo	Cuándo conviene	Límite
Excel o Google Sheets	Tablas dinámicas y gráficos simples	Sheets es gratis; Excel viene con Microsoft 365	Primer paso de cualquier pyme	Se traba con muchos datos y con varias personas editando
Power BI	Tableros interactivos conectados a Excel, bases de datos o un ERP	Gratis para crear; para compartir, USD 14 por usuario al mes	Empresas que ya usan Microsoft	Solo Windows, y compartir cuesta
Looker Studio	Tableros en la web	Gratis	Pymes que ya usan Google Sheets o Drive	Depende de la nube de Google
Tableau	Visualización avanzada	Pago, por usuario	Empresas grandes con equipo de análisis	Caro para una pyme
Metabase	Tableros y consultas sobre la base de datos del sistema	Open source, gratis en un servidor propio	Pymes con un sistema de gestión y alguien técnico	Hay que instalar y mantener el servidor
Apache Superset	Tableros avanzados	Open source, gratis en un servidor propio	Equipos con perfil técnico	Más complejo de instalar

Para preparar y predecir: programación

Herramienta	Para qué sirve	Costo
Python	El lenguaje más usado para trabajar con datos	Gratis, open source
pandas	Limpiar y transformar tablas dentro de Python	Gratis, open source
Google Colab	Escribir y correr Python en la nube, sin instalar nada	Gratis con límites; necesita internet

Herramienta	Para qué sirve	Costo
Jupyter	Lo mismo que Colab, pero en la propia computadora	Gratis, open source; funciona sin internet

Ejemplos de uso: un almacén anota sus ventas en Sheets y ve un gráfico semanal en Looker Studio. Una distribuidora conecta su ERP a Power BI y ve las ventas por vendedor cada mañana. Una planta registra sus paradas en una planilla y arma en Power BI un Pareto de causas. Una fábrica usa Python para pronosticar la demanda del mes siguiente o para detectar qué máquina se está desgastando.

Para los datos de máquinas se suman plataformas IoT, que reciben las lecturas de los sensores (el tema del grupo 1). El análisis posterior usa las mismas herramientas de estas tablas.

> **Lo que esto responde de la pregunta:** todo el camino hasta la predicción se puede hacer sin pagar licencias, con Python y herramientas gratuitas. Para ver los datos, Looker Studio, Metabase y Superset tampoco cobran licencia. El costo real no es el software, sino el tiempo de alguien que sepa usarlo.

Dicho con tus palabras (escalón 2)

- "Un dato no llega limpio: nace en una factura, en una planilla, en un WhatsApp o en el sensor de una máquina, y hay que ordenarlo antes de usarlo."
- "Basura entra, basura sale: si cargamos mal los datos, el mejor modelo del mundo se equivoca."
- "Para empezar no hace falta pagar licencias: con Python y herramientas gratuitas se llega hasta la predicción."
- **Línea de cierre del bloque:** "Para que los datos sirvan, tienen que pasar una revisión de calidad que se repita siempre igual. Con datos así, ya podemos intentar anticipar lo que va a pasar."

Te pueden preguntar (escalón 2)

Pregunta	Cómo responder
¿Qué hacen con los datos que faltan?	Si son pocos, se descartan y se documenta cuántos. Si son muchos, se completan con un método razonable. En el escalón 3 medimos cuánto empeora el pronóstico cuando faltan datos.
¿Por qué Colab y no algo instalado?	Porque es gratis y no hay que instalar nada. Si falla internet, el mismo notebook corre en Jupyter, y llevamos uno ya ejecutado de respaldo.
¿Cuánto cuesta todo esto?	En licencias, cero para preparar datos y predecir. Power BI solo cobra si hay que compartir tableros. El costo real es capacitar a alguien.
¿Por qué no hacer todo en Excel?	Sirve para empezar, pero tiene un máximo de filas por hoja y no deja registro de qué se hizo con los datos. Nuestro dataset llega justo a ese máximo.
¿Qué riesgo no mencionaron?	Depender de una sola persona que sabe Python. Se reduce documentando el notebook para que otra persona pueda correrlo.

Transición · ¿Cuándo conviene pasar a ML?

Franco · transición

No toda empresa necesita machine learning. Lo que necesita depende de su escala y de cuánto le cuesta equivocarse.

Las dos miradas suben la misma escalera

La celda resaltada es nuestra demo; la punteada es el contraste operativo

	1 · Registrar Micro · hasta 10	2 · Ver Pequeña · 11 a 30	3 · Entender Mediana · 31 a 50	4 · Anticipar Grande e industrial
Comercial	Ventas, stock y factura electrónica	KPIs de ventas y alertas de stock	Estacionalidad y pronóstico simple	**ML de demanda** por depósito
Operativa	Paradas, causas y producción diaria	OEE y defectos por línea	Causas de paradas y plan preventivo	ML para anticipar fallas de máquinas
Herramienta típica	Sistema de gestión (ej.: Focal Point)	Tablero: Looker Studio o Power BI	BI, Pareto y media móvil	Python, sensores y LightGBM

Pocos productos, transacciones y máquinas → Más volumen, más datos y más costo del error

Los números de cada columna son trabajadores, según la Ley 7444. Cada escalón necesita el anterior: no se puede anticipar lo que nunca se registró, ni en ventas ni en la planta.

Escala	Qué puede responder: comercial	Qué puede responder: operativa
Micro	¿Qué vendí hoy? ¿Qué está por agotarse?	¿Cuántas horas estuvo parada la máquina?
Pequeña	¿Qué productos rotan? ¿Dónde pierdo margen?	¿Qué línea tiene el OEE más bajo?
Mediana	¿Hay estacionalidad? ¿Cuánto voy a vender el mes que viene, aproximadamente?	¿Qué causa la mayoría de las paradas?
Grande e industrial	¿Cuánto stock tener en cada depósito?	¿Qué máquina va a fallar la semana que viene?

El matiz importante: lo que decide no es la cantidad de trabajadores, sino cuántos productos y transacciones hay y cuánto cuesta equivocarse. Con 20 productos alcanza el ojo del encargado; con 2.000, no. El tamaño de la empresa suele ir de la mano, pero no siempre.

Los requisitos no son los mismos para las dos miradas. Este contraste es parte de la respuesta a la pregunta:

Requisito	Para predecir demanda	Para predecir fallas
Dato base	Historia de ventas por producto y fecha	Lecturas de sensores y registro de cada falla
Quién lo tiene hoy	Casi toda pyme, en sus facturas	Muy pocas pymes
Frecuencia	Mensual o semanal alcanza	Minutos o segundos

Requisito	Para predecir demanda	Para predecir fallas
Dificultad principal	Separar tendencia, estacionalidad y ruido	Las fallas son raras: hay muy pocos ejemplos para aprender
Costo de arrancar	Bajo: los datos ya existen	Alto: sensores, instalación y conectividad

Criterios preliminares para pasar a ML (el experimento del escalón 3 los pone a prueba):

- **Historia continua:** al menos un año completo para ver la estacionalidad; el mínimo exacto lo mide el experimento.
- **Calidad revisada:** los datos pasaron el control del escalón 2.
- **Frecuencia acorde a la decisión:** mensual para planificar producción, diaria para reponer perecederos.
- **Volumen:** tantos productos que planificar a mano ya no alcanza.
- **Costo del error alto:** los quiebres, el sobrestock o una parada imprevista cuestan plata de verdad.
- **Con qué compararse y quién lo mantiene:** un método simple contra el cual medir el modelo, y una persona responsable.

Un ejemplo local del primer escalón: Focal Point. Es un sistema paraguayo pensado para micro y pequeñas empresas, y reúne lo que ese nivel necesita: facturación electrónica; inventario y stock, con alertas de stock bajo; punto de venta; datos de clientes y empleados; tienda online; un CRM para los mensajes de WhatsApp; y asistentes de IA para atención al cliente y consultas internas.

Lo mostramos como ejemplo del escalón de registro en la mirada comercial; en la operativa, ese primer paso es un registro ordenado de paradas y mantenimiento. Hay otros sistemas de gestión, y también se puede empezar con una planilla bien llevada. En la exposición hay que declararlo: Franco es co-fundador de Focal Point.

Escalón 3 · Anticipar

Franco · 15 min con el cierre

3.1 Qué es machine learning

Machine learning (ML) son programas que aprenden patrones a partir de ejemplos, en lugar de seguir reglas escritas a mano. Nosotros usamos **aprendizaje supervisado**: el modelo ve ejemplos con la respuesta conocida (las ventas pasadas) y aprende a estimar la respuesta de casos nuevos (las ventas futuras).

Hay dos tipos de preguntas, una por cada mirada:

- **Regresión o pronóstico:** cuánto. Por ejemplo, cuántos paquetes se van a vender el mes que viene. Es lo que hace nuestra demo.
- **Clasificación:** sí o no. Por ejemplo, si una máquina va a fallar esta semana. Es la base del mantenimiento predictivo.
- **Serie de tiempo:** datos ordenados en el tiempo. Se piensan como la suma de una tendencia (sube o baja a largo plazo), una estacionalidad (se repite cada año o cada semana) y ruido (lo que no se explica).
- **Variables (features):** lo que el modelo mira para predecir, por ejemplo la demanda del mes pasado, la del mismo mes del año anterior, el mes del año y el depósito.
- **Entrenamiento y prueba:** el modelo aprende con una parte del pasado y se lo evalúa con un período que no vio.
- **Sobreajuste:** el modelo memoriza el pasado en vez de aprender el patrón, como quien estudia de memoria las respuestas del examen del año anterior. Le va perfecto con lo viejo y mal con lo nuevo.

- **Validación temporal:** nunca se mezcla el futuro en el entrenamiento. Se entrena hasta una fecha, se prueba después y se repite desde varias fechas (Tashman, 2000).
- **Baseline:** un método simple contra el cual comparar. Si el modelo no le gana, no vale la pena.

3.2 Los modelos que comparamos

Modelo	Cómo piensa	Tipo
Naive estacional	"Este mes se vende lo mismo que el mismo mes del año pasado"	Baseline
Media móvil	"Se vende el promedio de los últimos meses"	Baseline
Croston	Para productos que se venden de vez en cuando: estima por separado cuánto y cada cuánto (Croston, 1972)	Clásico
LightGBM	Muchos árboles de decisión chicos, cada uno corrige los errores del anterior (Ke et al., 2017)	ML

En la competencia M5 de pronóstico de ventas, los métodos ganadores usaron LightGBM (Makridakis et al., 2022). Pero en las series mensuales de la competencia M3, los métodos estadísticos le ganaron al ML (Makridakis et al., 2018). El ML no gana siempre, y eso es justamente lo que medimos.

Para clasificar fallas se usan los mismos tipos de modelos, como LightGBM, entrenados con las lecturas de los sensores y el registro de las fallas pasadas.

3.3 Las métricas que vamos a usar

Métrica	Qué mide	Cómo se lee
MAE	Error promedio, en unidades	"Nos equivocamos en promedio por 47 paquetes"
WAPE	Error total dividido por la demanda total	"Nos equivocamos en un 23% del volumen"
Sesgo	Si el modelo tiende a pasarse o a quedarse corto	"Pronosticamos un 10% de más"
MASE	Error del modelo comparado con el del naive (Hyndman y Koehler, 2006)	Menor que 1: le gana al naive

Ejemplo con números inventados para entender las tres primeras:

Mes	Demanda real	Pronóstico	Error absoluto
Enero	200	220	20
Febrero	260	220	40
Marzo	140	220	80
Total	600	660	140

- MAE = 140 / 3 = 46,7 unidades.
- WAPE = 140 / 600 = 23,3%.
- Sesgo = (660 − 600) / 600 = +10%: el pronóstico se pasó.

No usamos el MAPE, que divide el error por la demanda de cada mes: si un mes la demanda es cero, la cuenta no se puede hacer, y eso pasa seguido con productos de poca venta.

Métricas para la mirada operativa (clasificación). Cuando el modelo responde sí o no, se mide distinto:

Métrica	Qué mide	Cómo se lee
Precisión	De las alarmas que dio el modelo, cuántas fueron fallas reales	"6 de cada 10 alarmas fueron fallas"
Recall (sensibilidad)	De las fallas reales, cuántas anticipó	"Anticipamos 8 de cada 10 fallas"
F1	Un promedio entre las dos	Sirve para comparar modelos con un solo número

Ejemplo con números inventados: en 1.000 días hubo 30 fallas. El modelo dio 40 alarmas y 24 fueron fallas reales.

- Precisión = 24 / 40 = 60%.
- Recall = 24 / 30 = 80%.
- F1 = 2 × 0,60 × 0,80 / (0,60 + 0,80) = 69%.

> **Por qué el accuracy engaña acá:** si el 3% de los días hay falla, un modelo que siempre dice "no va a fallar" acierta el 97% de las veces y no sirve para nada (He y Garcia, 2009).

3.4 Lo que se muestra en la demo

1. **El modelo contra los baselines**, sobre el dataset limpio del escalón 2.
2. **El experimento de madurez:** se repite todo con menos historia (6, 12, 24 y 36 meses), con datos faltantes agregados a propósito (5%, 15% y 30%) y con otra frecuencia (semanal y mensual). Así se simula a empresas menos maduras y se ve desde qué punto el ML le gana al método simple.
3. **Un momento de Blindside**, que se explica abajo.
4. **El contraste operativo:** la tabla de requisitos de la transición, para mostrar qué datos harían falta para predecir fallas.

3.5 Blindside: el dato que casi nadie registra

Blindside es el proyecto final de Franco en el Diplomado de Machine Learning de la FIUNA (Cazal, 2026). Pronostica la demanda de productos perecederos y muestra un problema que casi ninguna pyme registra: el **quiebre de stock**.

Cuando un producto se agota, la venta registrada es cero, pero la gente quería comprar. Si el modelo aprende de esas ventas, cree que la demanda es más baja: se pide menos, hay más quiebres y el error se agranda solo.

- Entrenar con las ventas registradas subestimó la demanda un 18,19%; corrigiendo los quiebres, el sesgo bajó a 6,61%.
- En la demo, al corregir los quiebres, la cantidad a pedir sube 27,3%.
- Una media móvil de 21 días ya mejoró 17,8% sobre el naive, y el mejor modelo de ML llegó a 25,3%: buena parte de la mejora la consigue un método simple.

> **La lección para la pregunta:** un requisito de madurez es **registrar cuándo un producto no estuvo disponible**. Es otro dominio y otros datos, así que lo usamos como evidencia y no como nuestro caso.

3.6 La respuesta a la pregunta

Pendiente: se completa con los resultados del experimento, en dos partes. **Comercial:** "Una pyme puede pasar de BI a ML de demanda cuando tiene al menos N meses de historia continua, menos de X% de datos faltantes, una frecuencia acorde a su decisión y registro de quiebres de stock." **Operativa:** "Para predecir fallas, el paso previo es medir la planta: sensores y un registro de cada falla. Sin eso, el nivel alcanzable es el mantenimiento preventivo." Las dos se pueden hacer sin licencias, con Python, Colab o Jupyter, y Looker Studio o Metabase.

Dicho con tus palabras (escalón 3)

- "Machine learning es aprender del pasado para anticipar el futuro, pero solo vale si le gana a algo simple."
- "Un modelo se prueba como un examen: con preguntas que no vio."
- "Predecir demanda se puede con los datos que una pyme ya tiene; predecir fallas exige primero medir la planta."
- "Si la empresa no registra cuándo se quedó sin stock, el modelo aprende una demanda más baja que la real."
- **Cierre de la exposición:** juntar las tres líneas de madurez en la respuesta de 3.6.

Te pueden preguntar (escalón 3)

Pregunta	Cómo responder
¿Por qué no usan deep learning o redes neuronales?	Con las series cortas de una pyme, los modelos complejos no ganan: en la M3 los métodos estadísticos superaron al ML, y en Blindside un modelo clásico empató con un promedio simple.
¿Por qué no hicieron también la demo de fallas?	Porque necesita datos de sensores que una pyme casi nunca tiene, y es el tema del grupo 5. Mostramos qué datos harían falta para llegar ahí.
¿Cómo validarían el umbral en una empresa real?	Con un piloto: usar el modelo junto al método actual de la empresa durante varios meses y comparar errores y quiebres.
¿Qué pasa si cambia el mercado, como en 2020?	El modelo pierde precisión. Se mide el error cada mes y se lo reentrena cuando empeora.
¿El modelo decide por la empresa?	No. Da un pronóstico y un rango; la decisión la toma una persona.
¿Por qué mencionan Focal Point?	Como ejemplo del escalón de registro. Lo declaramos porque Franco es co-fundador, y mostramos alternativas.
¿Qué riesgo no mencionaron?	Los datos de clientes y ventas son sensibles: hay que anonimizarlos y controlar quién accede.

Glosario

Término	Significado
Baseline	Método simple contra el cual se compara un modelo
BI (inteligencia de negocios)	Reportes y dashboards que muestran qué pasó

Término	Significado
Big Data	Datos tan grandes, rápidos o variados que las herramientas comunes no alcanzan
Clasificación	Modelo que responde sí o no, por ejemplo si una máquina va a fallar
CRISP-DM	Metodología de seis fases para proyectos de datos
Dashboard	Pantalla única con los indicadores más importantes
Dataset	Conjunto de datos ordenado en filas y columnas
Demanda censurada	Demanda que no quedó registrada porque el producto se agotó
EDA	Análisis exploratorio: mirar los datos antes de modelar
ERP	Sistema de gestión que registra ventas, stock, compras y clientes
Estacionalidad	Patrón que se repite cada año, mes o semana
ETL	Extraer, transformar y cargar datos
Feature (variable)	Dato que el modelo usa para predecir
IoT	Sensores conectados que envían datos de las máquinas
KPI	Indicador clave de desempeño
LightGBM	Modelo de ML basado en muchos árboles de decisión
Machine learning	Programas que aprenden patrones a partir de ejemplos
MAE, WAPE, MASE, sesgo	Métricas del error de un pronóstico (ver 3.3)
Mantenimiento predictivo	Reparar una máquina antes de que falle, según lo que indican sus datos
Mantenimiento preventivo	Reparar una máquina cada cierto tiempo fijo, falle o no
MTBF y MTTR	Tiempo medio entre fallas y tiempo medio de reparación
Naive	Pronóstico que repite el último valor, o el del mismo período anterior
OEE	Eficiencia global de un equipo: disponibilidad × rendimiento × calidad
Open source	Software de código abierto, que se puede usar sin pagar licencia
Pipeline	Cadena de pasos que lleva un dato de su origen a un gráfico o a un modelo
Precisión y recall	Métricas de un modelo de clasificación (ver 3.3)
Quiebre de stock	Momento en que un producto se agota
Regresión	Modelo que responde cuánto, por ejemplo cuánto se va a vender
Serie de tiempo	Datos ordenados en el tiempo
Sobreajuste	Cuando el modelo memoriza el pasado y falla con lo nuevo
Validación temporal	Probar el modelo con fechas posteriores a las que usó para aprender

Fuentes

Las referencias completas en formato APA están en el informe técnico.

- Cazal, F. (2026). Blindside [Proyecto final, Diplomado en ML y DL Aplicado, FIUNA].
- Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly, 23*(3), 289–303.
- Díaz, D. (2020). Hecho en Py: Fideos Napoli espera un 2021 favorable para la exportación. *InfoNegocios*.
- Few, S. (2006). *Information dashboard design*. O'Reilly Media.
- He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284.
- Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688.
- ISO/IEC. (2008). *ISO/IEC 25012:2008, Data quality model*.
- Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems 30*.
- Laney, D. (2001). *3D data management: Controlling data volume, velocity and variety*. META Group.
- Lee, J., Kao, H.-A., y Yang, S. (2014). Service innovation and smart analytics for Industry 4.0 and big data environment. *Procedia CIRP, 16*, 3–8.
- Ley N° 7444 (2025). Modifica y amplía la Ley N° 4457/2012 de MIPYMES.
- Makridakis, S., Spiliotis, E., y Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods. *PLOS ONE, 13*(3).
- Makridakis, S., Spiliotis, E., y Assimakopoulos, V. (2022). M5 accuracy competition. *International Journal of Forecasting, 38*(4).
- Nakajima, S. (1988). *Introduction to TPM: Total productive maintenance*. Productivity Press.
- PNUD (2025a). ¿Qué tan preparadas están las MIPYMES en Paraguay para la transformación digital?
- PNUD (2025b). Digitalización y MIPYMES en Paraguay: madurez digital y espíritu emprendedor
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy. *International Journal of Forecasting, 16*(4), 437–450.
- The Register (2025). Precios de Power BI desde abril de 2025.
- Última Hora (2026). DNIT incorporó a 5.961 emisores electrónicos en menos de dos meses.
- Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining.